

Relatório Técnico: Predição da Severidade de Acidentes Rodoviários em Seattle

Trabalho 2 — T326 Ciência de Dados | LCDIA — Universidade de Fortaleza

Integrantes:

- Gustavo Vinhas Nogueira — Matrícula 2310366
- Fabrício Oliveira de Sousa — Matrícula 2310346
- Wadson Gurgel Sátiro — Matrícula 1320529

1. Introdução

1.1 Descrição do Problema

A segurança rodoviária é um dos pilares da gestão urbana moderna. Acidentes de trânsito geram custos humanos e econômicos elevados, e a capacidade de antecipar a gravidade de uma colisão a partir das suas circunstâncias permite priorizar respostas de emergência e ações de prevenção. O problema central deste trabalho é: **dado o conjunto de condições em que uma colisão ocorre (local, clima, via, iluminação, tipo de colisão, envolvidos), é possível prever a sua severidade?**

1.2 Objetivo do Trabalho

Desenvolver e avaliar modelos de Aprendizado de Máquina capazes de classificar a severidade de acidentes rodoviários na cidade de Seattle, com base em fatores circunstanciais, temporais e ambientais, aplicando um fluxo completo de ciência de dados: análise exploratória, pré-processamento rigoroso (com prevenção de vazamento de dados), modelagem com pelo menos dois algoritmos e avaliação crítica com métricas adequadas ao desbalanceamento.

2. Dataset

2.1 Fonte dos Dados

Conjunto de dados *Vehicle Collision Data in Seattle (2005–2019)*, disponível na plataforma Kaggle, contendo o histórico de colisões registradas pela cidade de Seattle. O conjunto possui **111.882 registros** e **34 colunas**.

2.2 Tipo do Problema

Trata-se de um problema de **classificação supervisionada multiclasse**, em que o alvo SEVERITYCODE é um código ordinal com 4 níveis crescentes de severidade. O significado de cada código foi **confirmado a partir do próprio dataset**, cruzando-se o alvo com as colunas de consequência (INJURIES, SERIOUSINJURIES, FATALITIES):

Código	Significado	Validação (cruzamento)
--------	-------------	------------------------

0	Apenas Danos Materiais	0% de feridos, graves ou fatais
1	Ferimentos (leves)	100% com feridos; 0% graves/fatais
2	Ferimentos Graves	100% com feridos graves; 0% fatais
3	Fatalidade	100% com fatalidade

Esse esquema corresponde à escala oficial de severidade do *Seattle Department of Transportation* (Danos Materiais → Ferimento → Ferimento Grave → Fatalidade).

2.3 Descrição das Principais Variáveis

Grupo	Variáveis	Descrição
Alvo	SEVERITYCODE	Severidade da colisão: 0 (danos materiais), 1 (ferimentos), 2 (ferimentos graves), 3 (fatalidade)
Localização	longitude, latitude	Coordenadas geográficas do acidente
Características	COLLISIONTYPE, JUNCTIONTYPE	Tipo de colisão e tipo de cruzamento/via
Envolvidos	PERSONCOUNT, PEDCOUNT, PEDCYLCOUNT, VEHCOUNT	Contagem de pessoas, pedestres, ciclistas e veículos
Comportamento	SPEEDING, UNDERINFL, INATTENTIONIND, HITPARKEDCAR, intersection_related	Indicadores booleanos (excesso de velocidade, sob influência, desatenção, etc.)
Condições	WEATHER, ROADCOND, LIGHTCOND	Clima, condição da via e iluminação no momento
Meteorologia	AWND, PRCP, SNOW, SNWD, TAVG, TMAX, TMIN, WSF5	Vento, precipitação, neve e temperatura
Temporais	DATE, TIME	Data e hora do acidente
Pós-acidente	INJURIES, SERIOUSINJURIES, FATALITIES	Consequências do acidente (não usadas — ver 3.2)

3. Análise e Pré-processamento

3.1 Análise Exploratória dos Dados (EDA)

Distribuição do alvo: a análise revelou forte desbalanceamento de classes:

Classe	Significado	Proporção
0	Danos materiais	64,33%
1	Ferimentos	33,79%
2	Ferimentos graves	1,71%
3	Fatalidade	0,17%

As classes 2 e 3 somam menos de 2% dos dados. Isso define o **baseline**: prever sempre a classe majoritária (Classe 0) daria acurácia de **64,33%** — limiar que qualquer modelo deve superar. Pela criticidade das classes graves, a métrica primária adotada é o **F1-Score Macro**, que pesa igualmente todas as classes.




Figura 1 — Distribuição da variável alvo SEVERITYCODE.

Correlações e multicolinearidade: a matriz de correlação de Pearson identificou pares de variáveis fortemente correlacionadas entre si ($|r| > 0,8$): TAVG×TMAX (0,969), TAVG×TMIN (0,954), TMAX×TMIN (0,875) e AWND×WSF5 (0,814) — indicando redundância a ser tratada.




Figura 2 — Matriz de correlação de Pearson entre as variáveis numéricas.

Relevância das features: como a correlação de Pearson é limitada para alvos multiclasse, calculou-se a **Informação Mútua** entre cada variável e o alvo. As mais informativas foram VEHCOUNT (0,082), PEDCOUNT (0,043), longitude (0,041) e latitude (0,040). As variáveis meteorológicas apresentaram informação mútua próxima de zero, indicando baixo poder preditivo isolado.




Figura 3 — Ranking de Informação Mútua das features com o alvo.

Valores ausentes: identificaram-se nulos relevantes em response_type/response_time (86,55%), SNOW/SNWD (24,19%) e WSF5 (1,21%).

3.2 Prevenção de Vazamento de Dados (Data Leakage)

Identificou-se que INJURIES, SERIOUSINJURIES e FATALITIES constituem **vazamento de dados**: são preenchidas *a posteriori*, após a avaliação do acidente. Incluí-las geraria um modelo com desempenho artificial em treino e inútil na prática, pois não estão disponíveis no momento do registro inicial. Foram excluídas **antes da divisão dos dados**.

3.3 Tratamentos Realizados

- **Colunas removidas**: variáveis de vazamento; multicolineares (TMAX, TMIN, WSF5); com >50% de nulos (response_type, response_time); e identificadores (Unnamed: 0, SPDCASENO).
- **Duplicatas**: registros integralmente duplicados foram removidos.
- **Valores ausentes**: SNOW e SNWD imputados com 0 (ausência de neve é informativa); demais numéricas com a mediana e categóricas com a moda.
- **Outliers**: PERSONCOUNT e VEHCOUNT limitados ao percentil 99 (capping). PEDCOUNT e PEDCYLCOUNT mantidos, pois seus valores altos são raros mas legítimos e preditivos.

3.4 Transformações Aplicadas

- **Features temporais**: extraídas de DATE (mês, dia da semana) e TIME (hora do dia, armazenada em horas decimais).
- **One-Hot Encoding** (drop_first=True): COLLISIONTYPE, WEATHER, ROADCOND, JUNCTIONTYPE.
- **LIGHTCOND**: mantida como variável ordinal inteira (0–3), pois já codifica níveis crescentes de iluminação.
- **Booleanas**: convertidas para inteiro (0/1).
- **Padronização**: StandardScaler nas features contínuas e ordinais, com fit **apenas no treino** e transform em treino e teste, evitando vazamento estatístico.
- **Divisão**: 80% treino / 20% teste, **estratificada** (stratify=y), preservando a distribuição de classes.

4. Modelagem

4.1 Modelos Utilizados

Foram selecionados dois algoritmos de naturezas distintas:

1. **Regressão Logística (Multinomial)**: modelo linear baseline que estima as probabilidades das classes via função *softmax*. Configurado com max_iter=1000 para garantir convergência. Vantagem: interpretabilidade.
2. **Random Forest Classifier**: modelo não-linear baseado em *ensemble* de 100 árvores de decisão construídas por *bagging*, capaz de capturar interações complexas entre atributos.

4.2 Estratégia de Treinamento

Ambos os algoritmos foram parametrizados com class_weight='balanced', que penaliza erros nas classes minoritárias de forma inversamente proporcional à sua frequência, forçando a fronteira de decisão a considerar ferimentos e fatalidades. O treino foi feito sobre o conjunto padronizado de treino (80%) e a avaliação sobre o conjunto de teste (20%) independente. Usou-se random_state=42 para

reprodutibilidade.

5. Resultados

5.1 Métricas Utilizadas

A métrica primária é o **F1-Score Macro** (adequado ao desbalanceamento). Reportam-se também Acurácia, Precisão e Recall (macro), além das matrizes de confusão.

5.2 Comparação entre Modelos

Tabela 1: Desempenho Comparativo (Treino vs. Teste)

Métrica	LR (Treino)	LR (Teste)	RF (Treino)	RF (Teste)
Acurácia	0,5647	0,5597	1,0000	0,7152
Precisão (Macro)	0,3393	0,3357	1,0000	0,3451
Recall (Macro)	0,5332	0,4778	1,0000	0,3238
F1-Score (Macro)	0,3269	0,3219	1,0000	0,3239

Figura 4 — Matrizes de Confusão no conjunto de teste




Figura 4 — Matrizes de confusão no conjunto de teste. O Random Forest praticamente não prevê as classes 2 e 3 (colunas zeradas), enquanto a Regressão Logística tenta classificá-las, ao custo de mais falsos positivos.

5.3 Discussão dos Resultados

- **Regressão Logística:** consistência notável entre treino e teste (F1-Macro 0,3269 vs. 0,3219) — gap praticamente nulo, **ausência de overfitting**. Porém, o valor absoluto baixo indica **underfitting estrutural**: por ser linear, não captura combinações complexas. A acurácia (0,56) fica *abaixo* do baseline porque o `class_weight='balanced'` troca acurácia global por sensibilidade às classes minoritárias.
- **Random Forest: overfitting severo** — todas as métricas atingem 1,0000 no treino (memorização perfeita), mas o F1-Macro colapsa para 0,3239 no teste. As árvores cresceram sem restrição de profundidade. A acurácia de teste (0,7152) supera o baseline, mas o F1-Macro revela que o ganho

concentra-se nas classes majoritárias.

- **Classes minoritárias:** a Regressão Logística obteve Recall Macro de teste (0,4778) superior ao Random Forest (0,3238), sendo mais eficaz em identificar acidentes com feridos e fatalidades, ainda que gerando mais falsos positivos. As matrizes de confusão mostram que ambos ainda confundem bastante as classes raras.

6. Conclusão

6.1 Principais Aprendizados

O trabalho demonstrou um fluxo completo de ciência de dados aplicado a um problema real e desafiador. Os principais aprendizados foram:

- A **prevenção de vazamento de dados** é decisiva: incluir as variáveis de consequência (**INJURIES**, **FATALITIES**) inflaria artificialmente o desempenho, mas tornaria o modelo inútil na prática.
- Em conjuntos **fortemente desbalanceados**, a acurácia é enganosa — o F1-Score Macro e a análise por classe revelam o desempenho real, especialmente nas classes críticas.
- A comparação entre um modelo linear (Regressão Logística) e um *ensemble* (Random Forest) evidenciou de forma didática os fenômenos opostos de **underfitting** e **overfitting**.
- As features puramente circunstanciais disponíveis têm **baixo poder preditivo** sobre a severidade (confirmado pela Informação Mútua), o que limita o teto de desempenho alcançável.

6.2 Limitações e Possíveis Melhorias

Limitações:

1. A remoção obrigatória das variáveis de vazamento retirou os indicadores diretos de severidade; o comportamento humano (velocidade real, uso de cinto, sobriedade) — não registrado estruturadamente no momento inicial — é o que de fato determina a gravidade.
2. O Random Forest não sofreu poda, resultando no overfitting documentado.
3. O desbalanceamento extremo (classes 2 e 3 < 2%) limita o aprendizado dos padrões graves.

Possíveis melhorias:

- Regularizar o Random Forest (`max_depth`, `min_samples_leaf`).
- Explorar modelos de *Gradient Boosting* (XGBoost, LightGBM), mais robustos a desbalanceamento.
- Aplicar técnicas de reamostragem (SMOTE, undersampling).
- Engenharia de atributos avançada (variáveis de interação como "noite + chuva", horas de pico, fins de semana).
- Tunagem de hiperparâmetros via validação cruzada.

7. Referências

- Dataset: *Vehicle Collision Data in Seattle (2005–2019)* — Kaggle. Disponível em: <https://www.kaggle.com/datasets/mcfly1/vehicle-collision-data-in-seattle-2005-2019>
- Pedregosa et al. *Scikit-learn: Machine Learning in Python*. JMLR, 2011. <https://scikit-learn.org>
- McKinney, W. *Data Structures for Statistical Computing in Python* (pandas), 2010.